UPN
UNIVERSIDAD PRIVADA DEL NORTE

FACULTAD DE INGENIERÍA

CARRERA DE INGENIERÍA DE SISTEMAS COMPUTACIONALES

INFORME DE PROYECTO FINAL

BASE DE DATOS AVANZADAS Y BIG DATA

Solución de Inteligencia de Negocios y Solución Big Data

Factores asociados a la no-llegada de huéspedes en el sistema Estadía de Tunki Lodge

DATOS DEL EQUIPO	INFORMACIÓN	
Autores	Ayala Hernandez, Gerardo Bringas Veramendi, Julio Cesar Ricardo Osorio Carbajal, Mijai Racchumi Julon, Yeremi Adrian Valencia Amancio, Alex	100% 100% 100% 100% 100%
Docente	Victor Isaac Chavez Bardales	
Curso / NRC	Base de Datos Avanzadas y Big Data / 26055	
Repositorio	https://github.com/AlexAmancio/proyecto-bi-bigdata — rama main	
Período	2026-2	

Lima - Perú

2026

ORIENTACIONES PARA EL PROYECTO Y EL INFORME

Propósito del proyecto: desarrollar, integrar y evaluar una solución de Inteligencia de Negocios y una solución Big Data que respondan a una necesidad empresarial verificable. El informe debe demostrar decisiones de ingeniería, experimentación reproducible y dominio técnico de ambas soluciones.

Alineación referencial con ABET: este formato operacionaliza el Student Outcome 6 de ABET EAC mediante evidencias directas de diseño y ejecución de experimentos, análisis e interpretación de datos y conclusiones sustentadas con juicio de ingeniería.

Entregables obligatorios

N.°	ENTREGABLE	EVIDENCIA MÍNIMA
1	Informe técnico	Documento completo con citas válidas, tablas, figuras y trazabilidad de evidencias.
2	Solución BI functional	Modelo dimensional, ETL/ELT, almacén de datos o data mart, indicadores, análisis OLAP y dashboard.
3	Solución Big Data functional	Ingesta, almacenamiento y procesamiento escalable o distribuido, consultas/análisis y demostración técnica.
4	Paquete experimental	Dataset original y procesado, scripts/notebook, configuraciones, logs, métricas, resultados y visualizaciones.
5	Repositorio versionado	Código, documentación, historial de cambios, etiqueta de versión final y evidencia de aportes individuales.
6	Defensa y mejora	Demostración funcional, respuesta individual, retroalimentación recibida y mejoras implementadas.
7	Uso responsable de IA	Declaración de herramientas, propósito, verificación, autoría intelectual, privacidad y limitaciones.

Convenciones de presentación de evidencias

1. Identifique cada evidencia con un código único (por ejemplo, E-01, E-02) y úselo en el informe, anexos y repositorio.
2. Todo resultado debe indicar dataset, versión del código, configuración, fecha de ejecución y responsable.
3. Los enlaces deben ser accesibles para el docente y conservar una versión congelada del entregable final.
4. No reemplace el análisis técnico por capturas: las capturas complementan, pero no sustituyen, datasets, scripts, métricas, tablas y logs.
5. La evaluación del resultado de experimentación requiere evidencia individual además del producto grupal.

ÍNDICE

Actualice el índice automático después de completar el informe. Incluya además los índices de tablas, figuras y anexos.

Haga clic derecho y seleccione Actualizar campo para generar el índice.

RESUMEN

Las reservas en Tunki Lodge vienen cayendo y el sistema Estadía no ofrece ninguna forma de explicar por qué. Entre enero y octubre de 2026 se registraron 2 179 reservas frente a 2 909 en el mismo periodo de 2025 (−25.1 %), el ingreso cobrado bajó 30.2 % y la tasa de cancelación pasó de 5.1 % en enero a 19.2 % en septiembre, cuando en 2024 y 2025 se mantuvo estable en 5 %. El objetivo del proyecto fue diseñar e implementar una solución de Inteligencia de Negocios que explique esa caída e identifique en qué segmentos se concentra la no-llegada de huéspedes (cancelaciones y no-show). La solución integra la base operativa alquiler (SQL Server) y tres archivos planos en un datamart en esquema estrella (hotel_dw) con cinco dimensiones y cuatro medidas, mediante un proceso ETL en T-SQL de ocho pasos que aplica once reglas de calidad de datos, controla errores con TRY/CATCH, registra su consumo de tiempo, CPU y lecturas en una bitácora y se ejecuta de forma automática con el Programador de tareas de Windows. Los indicadores se presentan en un dashboard de Power BI con medidas DAX. El diseño experimental midió el costo del ETL con lotes de 500 a 15 000 estadías, la eficacia de las reglas de calidad con datos defectuosos y la coincidencia de los indicadores entre SQL y Power BI. El ETL carga 15 000 estadías en 3.5 s con un crecimiento casi lineal, detectó el 100 % de los 14 registros defectuosos inyectados y los indicadores coinciden en ambas herramientas. La no-llegada es tres veces mayor en clientes de ciudades lejanas (15.2 %) que en los de ciudades cercanas a Oxapampa (4.5 %) y dos veces mayor con pago en efectivo (13.5 %) que con transferencia (6.8 %). Se concluye que la caída se explica por el crecimiento de los segmentos de mayor riesgo, lo que permite orientar ofertas dirigidas en lugar de descuentos generales.

Palabras clave: inteligencia de negocios, datamart, proceso ETL, calidad de datos, Power BI

ABSTRACT

Bookings at Tunki Lodge have been falling, and the Estadía system offers no way to explain why. Between January and October 2026, 2,179 bookings were recorded versus 2,909 in the same period of 2025 (−25.1%), collected revenue dropped 30.2%, and the cancellation rate rose from 5.1% in January to 19.2% in September, whereas it remained stable at 5% in 2024 and 2025. The goal of the project was to design and implement a Business Intelligence solution that explains this decline and identifies the segments where guest no-arrivals (cancellations and no-shows) concentrate. The solution integrates the operational database (alquiler, SQL Server) and three flat files into a star-schema data mart (hotel_dw) with five dimensions and four measures, through an eight-step T-SQL ETL process that applies eleven data-quality rules, handles errors with TRY/CATCH, logs its time, CPU and reads, and runs automatically through Windows Task Scheduler. Indicators are presented in a Power BI dashboard with DAX measures. The experimental design measured the ETL cost with batches of 500 to 15,000 stays, the effectiveness of the quality rules with defective data, and the agreement of indicators between SQL and Power BI. The ETL loads 15,000 stays in 3.5 s with almost linear growth, detected 100% of the 14 injected defective records, and indicators match in both tools. No-arrivals are three times higher for guests from distant cities (15.2%) than for those from cities near Oxapampa (4.5%), and twice as high with cash payment (13.5%) as with bank transfer (6.8%). We conclude that the decline is explained by the growth of the highest-risk segments, which supports targeted offers instead of general discounts.

Keywords: business intelligence, data mart, ETL process, data quality, Power BI

CAPÍTULO I: CONTEXTO, PROBLEMA Y OBJETIVOS

1.1 Contexto y necesidad empresarial

Tunki Lodge, ubicado en Oxapampa (Pasco), opera con Estadía, un sistema web propio (Spring Boot y SQL Server) que cubre todo el ciclo de una estadía: registro de clientes, gestión de habitaciones y categorías, reservas simples y múltiples, check-in, consumos adicionales, check-out, cancelación, no-show y extensión de estadía, con roles de recepción y administrador. Su base operativa, alquiler, es la fuente de este proyecto. El hotel cuenta con 45 habitaciones en seis categorías, desde la Habitación Matrimonial (S/ 180 por noche) hasta la Cabaña Bungalow para 8 a 10 personas (S/ 450).

La señal que motiva el proyecto es una caída sostenida de las reservas. En 2024 el hotel registró 3 346 reservas y en 2025 creció a 3 511 (+4.9 %), con la temporada alta habitual en enero–marzo, julio y diciembre y una tasa de cancelación estable de 5 %. En 2026 la tendencia se invierte: entre enero y octubre se registraron 2 179 reservas frente a 2 909 en el mismo periodo de 2025 (−25.1 %), y cada mes quedó por debajo del mismo mes del año anterior, desde −7 % en enero hasta −59 % en octubre. Al mismo tiempo, la tasa de cancelación subió de 5.1 % en enero a 21.4 % en octubre, y el ingreso cobrado de enero a octubre bajó de S/ 1 885 999 a S/ 1 315 500 (−30.2 %).

El equipo administrativo no tiene forma de explicar esta caída: el sistema registra cada reserva, pero no consolida la información a lo largo del tiempo ni la compara por segmento. Los datos de estadías del periodo 2024–2026 (9 036 registros) son simulados con fines de análisis, siguiendo reglas de negocio que reproducen la operación del hotel; las categorías, habitaciones, productos de consumo y usuarios son los del sistema. Esa es la línea base cuantitativa del problema: las reservas caen mientras la no-llegada aumenta.

1.2 Formulación del problema de ingeniería

El problema de ingeniería de este proyecto es por qué han caído las reservas en Tunki Lodge y en qué segmentos del negocio se concentra el aumento de la no-llegada de huéspedes (cancelaciones y no-show). La no-llegada es el evento medible más directo: una habitación reservada que no se ocupa bloquea inventario sin generar ingreso y distorsiona la planificación de personal e insumos. La pregunta de fondo es si esa no-llegada se está volviendo más frecuente con el tiempo y qué características de la reserva la explican: la zona de origen del cliente, el método de pago, la categoría de habitación, el tamaño del grupo y si el cliente es nuevo o recurrente.

Las variables existen en el sistema operativo, pero nunca se consolidan a lo largo del tiempo ni se comparan periodo contra periodo, y el sistema no aplica controles de calidad sobre los datos que se analizan. Una restricción del problema es que el sistema no guarda la fecha en que se hizo la reserva, por lo que la anticipación no puede medirse con los datos disponibles. El problema requiere una solución de Inteligencia de Negocios porque hace falta integrar las fuentes en un modelo dimensional centrado en el tiempo, con un proceso de carga confiable y automatizado, que permita comparar mes contra mes y año contra año por segmento y presentar los resultados en un tablero que apoye decisiones comerciales.

1.3 Objetivos

Objetivo general: Diseñar e implementar una solución de Inteligencia de Negocios que explique la caída de reservas en el sistema Estadía de Tunki Lodge entre 2024 y 2026, identificando en qué segmentos (zona de origen del cliente, método de pago, categoría de habitación, tamaño del grupo y cliente nuevo o recurrente) se concentra el aumento de cancelaciones y no-show, con una diferencia de al menos 10 puntos porcentuales

entre el segmento de mayor y el de menor riesgo y una medición explícita de la variación de reservas mes contra mes y año contra año.

Objetivos específicos:

- ✓ **OE-01.** Construir un datamart en esquema estrella con al menos cinco dimensiones y cuatro medidas, alimentado por un proceso ETL que integre la base operativa alquiler y tres fuentes en archivos planos, con reconciliación del 100 % de las filas entre origen y destino.
- ✓ **OE-02.** Asegurar la calidad y la operación del proceso ETL mediante reglas de calidad de datos registradas, control de errores, bitácora de consumo y ejecución automática.
- ✓ **OE-03.** Calcular y visualizar en Power BI cuatro indicadores —variación interanual de reservas, tasa de cancelación, tasa de no-show e ingreso por estadía— segmentados por las variables del problema, para apoyar la decisión de ofertas dirigidas.
- ✓ **OE-04.** Diseñar y ejecutar al menos tres escenarios experimentales que midan el costo del ETL según el volumen de datos, la eficacia de las reglas de calidad y la coincidencia de los indicadores entre SQL y Power BI.

1.4 Alcance, restricciones y supuestos

Incluye las estadías registradas en el sistema Estadía entre enero de 2024 y octubre de 2026: clientes, habitaciones, categorías, consumos, usuarios y los cuatro estados de un registro (ACTIVA, FINALIZADA, CANCELADA y NO_SHOW), así como su integración en un datamart y su visualización en Power BI. No incluye predicción en tiempo real dentro de la aplicación web, integración con canales de reserva externos (OTA), datos de otros hoteles ni una solución Big Data.

Restricciones: (1) los datos de estadías, clientes y consumos son simulados con fines de análisis; se generaron con reglas que reproducen la estacionalidad del hotel y asignan a cada reserva un riesgo de no-llegada según su zona de origen, método de pago, categoría, tamaño de grupo y antecedentes del cliente. (2) La fecha de corte es el 23/10/2026: las reservas con llegada posterior figuran como ACTIVA o ya CANCELADA, por lo que octubre de 2026 es un mes incompleto. (3) El sistema no registra la fecha en que se hizo la reserva, por lo que la anticipación no forma parte del análisis. (4) La solución corre en la máquina de desarrollo del equipo, sin infraestructura cloud. Supuesto: las reglas de simulación representan de forma razonable el comportamiento del hotel; los hallazgos deben leerse como evidencia de los patrones que la solución es capaz de detectar, no como una medición exacta de la operación real.

1.5 Stakeholders y criterios de éxito

STAKEHOLDER	NECESIDAD / DECISIÓN	CRITERIO DE ÉXITO	EVIDENCIA
Administrador del hotel	Identificar qué reservas tienen mayor riesgo de no llegar, para exigir adelanto o reforzar la confirmación	Brecha de no-llegada de al menos 10 puntos porcentuales identificada entre el segmento de mayor y menor riesgo	E-07
Recepción (Usuario Normal)	Contar con un tablero con las reservas del mes y su tasa de cancelación y no-show	Dashboard en Power BI con los 4 indicadores, actualizado después de cada ejecución del ETL	E-07, E-13

STAKEHOLDER	NECESIDAD / DECISIÓN	CRITERIO DE ÉXITO	EVIDENCIA
Equipo de datos	Cargar el datamart de forma reproducible y conocer cuánto consume el proceso a medida que crece el volumen	ETL completo en menos de 5 s, origen = destino y consumo de tiempo, CPU y lecturas registrado en etl_log	E-10
Gerencia general de Tunki Lodge	Decidir medidas comerciales frente a la caída sostenida de reservas e ingresos	Comparación interanual (mismo mes 2025 frente a 2026) de reservas e ingresos disponible en el datamart	E-07
Área comercial / Marketing	Identificar los segmentos donde dirigir ofertas para recuperar reservas	Segmentación por zona de origen, método de pago, categoría y cliente recurrente disponible en el datamart	E-07

1.6 Fuentes, gobierno y ética de los datos

La fuente operativa es la base alquiler del sistema Estadía, en SQL Server, de propiedad del equipo y de uso interno. El proceso ETL la consume de dos formas: directamente, mediante consultas INSERT … SELECT para las dimensiones de categoría, cliente y usuario; y mediante tres archivos planos exportados del sistema (estadias.txt, consumos.txt y habitaciones.txt), que se cargan con BULK INSERT. Los datos de estadías, clientes y consumos del periodo 2024–2026 son simulados y no corresponden a personas reales; aun así, los datos personales (nombres, documento, teléfono, correo) no se llevan al datamart más allá de lo necesario para el análisis, y las contraseñas de los usuarios del sistema se guardan cifradas (BCrypt) y nunca se cargan en hotel_dw.

La calidad del ETL se valida por reconciliación entre el origen y el datamart (sección 6.1). Los scripts, los archivos planos y la documentación se conservan versionados en el repositorio. El principal riesgo de sesgo es que los patrones del dataset provienen de reglas de simulación definidas por el equipo; por eso se declara explícitamente que los hallazgos cuantitativos muestran la capacidad de la solución para detectar esos patrones y no deben leerse como una medición exacta del comportamiento real del hotel.

CAPÍTULO II: ANTECEDENTES Y FUNDAMENTOS

2.1 Antecedentes

Antecedente 1. Antonio, N., de Almeida, A., y Nunes, L. (2017). Predicting hotel bookings cancellation with a machine learning classification model. En 2017 16th IEEE International Conference on Machine Learning and Applications (ICMLA) (pp. 1049-1054). IEEE.

Problema: los hoteles no distinguen, en el momento de la reserva, cuáles probablemente se cancelarán, lo que distorsiona su cálculo de demanda neta. Método: un modelo de clasificación entrenado a diario sobre los datos del sistema de gestión de propiedades (PMS) del hotel. Datos: reservas reales de una cadena hotelera portuguesa. Métricas: precisión del modelo para recalcular la demanda neta. Resultado: el modelo permite descontar cancelaciones probables de la demanda bruta. Aporte al proyecto: motivó analizar los factores de la reserva que el sistema sí registra; como Estadía no guarda la fecha en que se hizo la reserva, la anticipación queda como recomendación para una siguiente versión (capítulo VII).

Antecedente 2. Antonio, N., de Almeida, A., y Nunes, L. (2019). Big data in hotel revenue management: Exploring cancellation drivers to gain insights into booking cancellation behavior. Cornell Hospitality Quarterly, 60(4), 298-319. https://doi.org/10.1177/1938965519851466

Problema: los hoteles generan grandes volúmenes de datos de reserva sin aprovecharlos para entender la cancelación. Método: análisis de factores asociados a la cancelación ("cancellation drivers") sobre datos históricos a gran escala. Datos: reservas de varios hoteles portugueses. Métricas: variables asociadas a la cancelación (antelación, segmento, temporada). Resultado: la antelación de la reserva y el tipo de habitación están entre los factores más asociados a la cancelación. Aporte al proyecto: respalda segmentar el análisis por categoría de habitación y por características del cliente y de la reserva, como se hace en el datamart de este proyecto.

Antecedente 3. Chen, S., Ngai, E. W. T., Ku, Y., Xu, Z., Gou, X., y Zhang, C. (2023). Prediction of hotel booking cancellations: Integration of machine learning and probability model based on interpretable feature interaction. Decision Support Systems, 170, 113959. https://doi.org/10.1016/j.dss.2023.113959

Problema: los modelos de predicción de cancelación suelen ser precisos pero poco interpretables para la operación del hotel. Método: integración de un modelo probabilístico (red bayesiana) con un modelo de aprendizaje automático interpretable. Datos: reservas hoteleras reales. Métricas: desempeño predictivo y ranking de variables por importancia. Resultado: el modelo integrado mejora la interpretabilidad sin perder desempeño. Aporte al proyecto: valida que reportar la tasa de no-llegada segmentada (por zona de origen, método de pago y categoría, como en el capítulo VI de este informe) es más útil para la decisión operativa que un único indicador agregado.

Antecedente 4. Kirmani, M. M. (2017). Dimensional modeling using star schema for data warehouse creation. Oriental Journal of Computer Science and Technology, 10(3), 745-754.

Problema: falta de un procedimiento claro para transformar un modelo entidad-relación operativo en un modelo dimensional. Método: un algoritmo de transformación de diagramas entidad-relación a esquema estrella. Datos: casos de estudio de bases de datos transaccionales. Métricas: cobertura de tablas de hechos y dimensiones generadas. Resultado: un procedimiento reproducible para construir el esquema estrella a partir del modelo operativo. Aporte al proyecto: se siguió este procedimiento para transformar el modelo entidad-relación de alquiler (registro, cliente, habitacion, categoria) en el esquema estrella hotel_dw de este proyecto.

Antecedente 5. Golfarelli, M., y Rizzi, S. (2018). From star schemas to big data: 20+ years of data warehouse research. En S. Flesca, S. Greco, E. Masciari, y D. Saccà (Eds.), A comprehensive guide through the Italian

database research over the last 25 years (Studies in Big Data, Vol. 31, pp. 93-107). Springer. https://doi.org/10.1007/978-3-319-61893-7_6

Problema: cómo evoluciona el data warehouse clásico frente a la llegada del Big Data. Método: revisión de más de 20 años de investigación en almacenamiento de datos. Datos: literatura académica del área (no aplica dataset). Métricas: no aplica, es una revisión. Resultado: los principios del modelado dimensional siguen vigentes como capa de consumo, incluso cuando el procesamiento subyacente es distribuido. Aporte al proyecto: sustenta el uso del esquema estrella hotel_dw como capa de consumo para el análisis OLAP y el dashboard.

2.2 Fundamentos de Inteligencia de Negocios

La integración de datos consiste en reunir en un único repositorio analítico la información que en el sistema Estadía vive repartida en tablas operativas independientes (cliente, habitacion, categoria, usuario, registro y consumo). El mecanismo usado para esa integración es un proceso ETL: se extraen (Extract) los datos de la base alquiler y de tres archivos planos, se transforman (Transform) —por ejemplo, sumando los consumos de cada estadía, calculando el saldo pendiente como tarifa más consumos menos lo pagado, clasificando al cliente por zona de origen y marcando si la estadía se canceló, fue no-show o se completó— y se cargan (Load) en un almacén separado, hotel_dw.

El modelado dimensional (Kimball y Ross, 2013; Kirmani, 2017) organiza ese almacén en una tabla de hechos, fact_estadia, con una fila por estadía y sus medidas (noches, cantidad de estadías, monto pagado y total de consumos), rodeada de tablas de dimensiones (dim_tiempo, dim_cliente, dim_habitacion, dim_categoria y dim_usuario) que describen el contexto de cada hecho. Cuando todas las dimensiones se conectan directamente con la tabla de hechos, el modelo es un esquema estrella; si una dimensión depende de otra, se convierte en un copo de nieve. Como hotel_dw cubre un único proceso de negocio —la estadía— y no toda la operación del hotel, técnicamente es un datamart y no un data warehouse corporativo.

Sobre ese modelo se ejecutan consultas OLAP: agregaciones multidimensionales que cruzan la tabla de hechos con una o más dimensiones, como la tasa de cancelación por mes o la no-llegada por zona de origen y método de pago. Esas consultas alimentan los indicadores del proyecto y su visualización en Power BI, que permite a un usuario no técnico, como el administrador o la gerencia, filtrar y comparar los resultados sin escribir consultas.

2.3 Fundamentos de Big Data

Big Data se refiere a conjuntos de datos cuyo volumen, velocidad o variedad superan la capacidad de las herramientas tradicionales de una sola máquina y requieren almacenamiento y procesamiento distribuido. En este proyecto se evaluó si esa condición se cumple: el volumen operativo (9 036 estadías en tres años, alrededor de 2 MB) es estructurado, llega por lotes y se procesa en una sola instancia de SQL Server en menos de 4 segundos, incluso al duplicarlo a 15 000 estadías (capítulo VI). Por ello, el alcance de esta entrega se centra en la solución de Inteligencia de Negocios; el uso de procesamiento distribuido queda como recomendación para un escenario con varias sedes o varios años de historia adicional.

2.4 Tecnologías, estándares y trabajos relacionados

Se usa SQL Server 2025 tanto para la base operativa alquiler como para el datamart hotel_dw. Mantener ambas bases en la misma instancia permite que el ETL lea las tablas de origen directamente con consultas entre bases (INSERT … SELECT) y cargue archivos planos con BULK INSERT, sin herramientas intermedias. La alternativa de usar un servicio de integración (por ejemplo, SSIS) se descartó porque el volumen actual no lo justifica y un script T-SQL es más fácil de versionar, revisar y reproducir. Para automatizar la carga se compararon SQL Server

Agent y el Programador de tareas de Windows; se eligió este último, junto con sqlcmd, porque no requiere permisos de administrador ni servicios adicionales y funciona en cualquier equipo con SQL Server.

Para la visualización se eligió Power BI Desktop, que se conecta de forma nativa a SQL Server, reconoce las relaciones del esquema estrella y permite definir los indicadores como medidas DAX con funciones de inteligencia de tiempo (SAMEPERIODLASTYEAR). El reporte se guarda como proyecto de Power BI (.pbip), un formato de texto que se puede versionar en el repositorio. Los criterios de selección fueron integración con el origen, costo (edición Developer de SQL Server y Power BI Desktop sin licencia de pago), reproducibilidad y facilidad de uso para usuarios del negocio.

CAPÍTULO III: DISEÑO DE INGENIERÍA DE LAS SOLUCIONES

3.1 Requerimientos funcionales y no funcionales

RF-01 El proceso ETL debe integrar la base alquiler y tres archivos planos (estadias.txt, consumos.txt y habitaciones.txt) en hotel_dw sin pérdida de filas válidas.

RF-02 El datamart debe permitir calcular la variación interanual de reservas y las tasas de cancelación y no-show, segmentadas por mes, año, zona de origen, método de pago, categoría, tamaño del grupo y cliente nuevo o recurrente.

RF-03 El ETL debe aplicar reglas de calidad de datos (duplicados, valores inválidos, referencias inexistentes) y registrar en una tabla cuántos registros corrigió o descartó cada regla.

RF-04 El ETL debe registrar, por cada paso, su estado (OK/ERROR), duración, tiempo de CPU, lecturas lógicas y filas cargadas, y continuar o informar el error si una fuente falla.

RF-05 La solución debe presentar los indicadores en un dashboard interactivo de Power BI conectado a hotel_dw.

RNF-01 El ETL completo debe ejecutarse en menos de 5 segundos sobre el volumen actual (9 036 estadías) y poder repetirse sin duplicar datos.

RNF-02 El ETL debe poder ejecutarse de forma automática, sin abrir SQL Server Management Studio.

RNF-03 La solución debe poder reproducirse desde cero con los scripts del repositorio, ejecutando cada uno en una sola corrida.

RNF-04 Las credenciales de la base de datos no deben escribirse en el código ni en el repositorio.

3.2 Alternativas y decisiones de arquitectura

ALTERNATIVA	CRITERIOS	VENTAJAS	LIMITACIONES / RIESGOS	DECISIÓN
Motor del datamart	Costo, integración con el OLTP, curva de aprendizaje	SQL Server en la misma instancia que alquiler: consultas entre bases, BULK INSERT y funciones de fecha nativas	Una sola instancia concentra la carga operativa y la analítica	Seleccionada: SQL Server 2025 (hotel_dw)
Herramienta ETL	Reproducibilidad, versionado, simplicidad	Scripts T-SQL: se versionan como texto y se ejecutan en una sola corrida	Sin interfaz gráfica de flujo (como SSIS)	Seleccionada: crear_datamart.sql y ETL_CARGA.sql
Calidad de datos	Trazabilidad, sencillez	Reglas SQL sobre staging, registradas en etl_calidad	Las reglas se mantienen a mano en el script	Seleccionada: 11 reglas en el paso 6 del ETL
Automatización	Permisos, disponibilidad, simplicidad	Programador de tareas + sqlcmd: sin permisos de administrador ni servicios adicionales	Menos opciones de alerta que SQL Server Agent	Seleccionada: ejecutar_etl.bat y programar_etl.bat; SQL Server Agent como alternativa

ALTERNATIVA	CRITERIOS	VENTAJAS	LIMITACIONES / RIESGOS	DECISIÓN
Visualización	Conexión a SQL Server, uso por el negocio	Power BI: conexión nativa, esquema estrella, medidas DAX y filtros interactivos	Edición en Windows (Power BI Desktop)	Seleccionada: Power BI Desktop (.pbip)

3.3 Arquitectura integrada y flujo de datos

El sistema Estadía (Spring Boot y la base alquiler en SQL Server) es la fuente OLTP del proyecto. El ETL extrae los datos de alquiler en dos formas —consultas directas para categoría, cliente y usuario, y tres archivos planos para estadías, consumos y habitaciones—, los deposita en tablas de staging, aplica las reglas de calidad, transforma y carga el datamart hotel_dw, un esquema estrella en la misma instancia de SQL Server. Cada paso deja su estado y consumo en etl_log, y cada regla de calidad deja su resultado en etl_calidad. Un archivo por lotes (ejecutar_etl.bat) ejecuta el ETL con sqlcmd y el Programador de tareas de Windows lo lanza todos los días a las 23:00. Power BI se conecta a hotel_dw, actualiza el modelo y presenta los indicadores.

En seguridad, la aplicación controla el acceso con Spring Security y la contraseña de la base se pasa por variable de entorno; la tarea programada y Power BI se conectan con autenticación de Windows; todos los componentes corren en la máquina de desarrollo, sin exposición a internet.

Figura 1. Arquitectura de la solución BI: alquiler (SQL Server) + archivos planos → staging → reglas de calidad → hotel_dw (esquema estrella) → Power BI; ejecución automática con ejecutar_etl.bat y el Programador de tareas. Fuente: elaboración propia (evidencia E-05).

3.4 Diseño de la solución de Inteligencia de Negocios

3.4.1 Requisitos, usuarios e indicadores

Pregunta de negocio 1: ¿cuánto han caído las reservas mes a mes y frente al mismo mes del año anterior? Usuario: gerencia general. Decisión: si aplicar medidas comerciales y en qué meses.

Pregunta de negocio 2: ¿qué segmentos concentran el aumento de cancelaciones y no-show? Usuarios: administrador y área comercial. Decisión: a qué segmentos dirigir ofertas y en cuáles exigir adelanto o reforzar la confirmación.

Los indicadores se calculan sobre fact_estadia, unida a sus dimensiones, con frecuencia de actualización igual a cada ejecución del ETL:

INDICADOR (KPI)	FÓRMULA	GRANULARIDAD Y FILTROS	META / USO
KPI 1. Variación mensual de reservas	(reservas del mes − reservas del mismo mes del año anterior) / reservas del mismo mes del año anterior × 100	Mes y año del check-in	Detectar meses con caída mayor a 10 %
KPI 2. Tasa de cancelación	estadías canceladas / total de estadías × 100	Mes, zona, método de pago, categoría, cliente recurrente	Volver al nivel de 2024–2025 (5 %)
KPI 3. Tasa de no-show	estadías no-show / total de estadías × 100	Mes, zona, método de pago, categoría	Volver al nivel de 2024–2025 (3 %)

INDICADOR (KPI)	FÓRMULA	GRANULARIDAD Y FILTROS	META / USO
KPI 4. Ingreso por estadía	monto pagado / estadías finalizadas	Mes, categoría	Seguimiento del ingreso real por huésped que llega

3.4.2 Modelo dimensional y almacén de datos

El modelo es un esquema estrella con una tabla de hechos, fact_estadia, cuyo grano es una fila por registro de estadía. Tiene cuatro medidas: noches (noches vendidas), cantidad_estadias (1 por fila, para contar), monto_pagado (dinero cobrado) y total_consumos (suma de los consumos adicionales de la estadía). Incluye además atributos para filtrar y calcular los indicadores: estado, metodo_pago, num_huespedes, tarifa, saldo_pendiente, es_cliente_recurrente y las banderas es_cancelada, es_no_show y es_finalizada.

Las cinco dimensiones se conectan directamente con la tabla de hechos:

- ✓ **dim_tiempo:** una fila por día, con clave inteligente AAAAMMDD; atributos fecha, año, mes, nombre del mes, día, día de la semana, fin de semana y trimestre (1 035 días, del 01/01/2024 al 31/10/2026).
- ✓ **dim_cliente:** nombres, apellidos, país, ciudad, ocupación y zona de origen (Cercana, Lima, Lejana o Extranjero), calculada en el ETL según la distancia a Oxapampa.
- ✓ **dim_habitacion:** número, piso y aforo.
- ✓ **dim_categoria:** nombre de la categoría y precio base.
- ✓ **dim_usuario:** usuario del sistema que registró la estadía y si es administrador.

A nivel lógico y físico, id_registro es la clave primaria de los hechos y cada dimensión aporta su clave como clave foránea en fact_estadia (id_tiempo_checkin, id_cliente, id_habitacion, id_categoria e id_usuario), con las restricciones declaradas en la base. La categoría se conecta directamente con los hechos, y no a través de la habitación, para mantener un esquema estrella y evitar un copo de nieve. El datamart incluye tres tablas de staging, que reciben los archivos planos, y la tabla etl_log, donde el ETL registra su consumo. No se implementaron dimensiones de cambio lento (SCD), porque el proceso recarga una fotografía completa del estado actual. La definición completa está en bi/crear_datamart.sql (evidencia E-06).

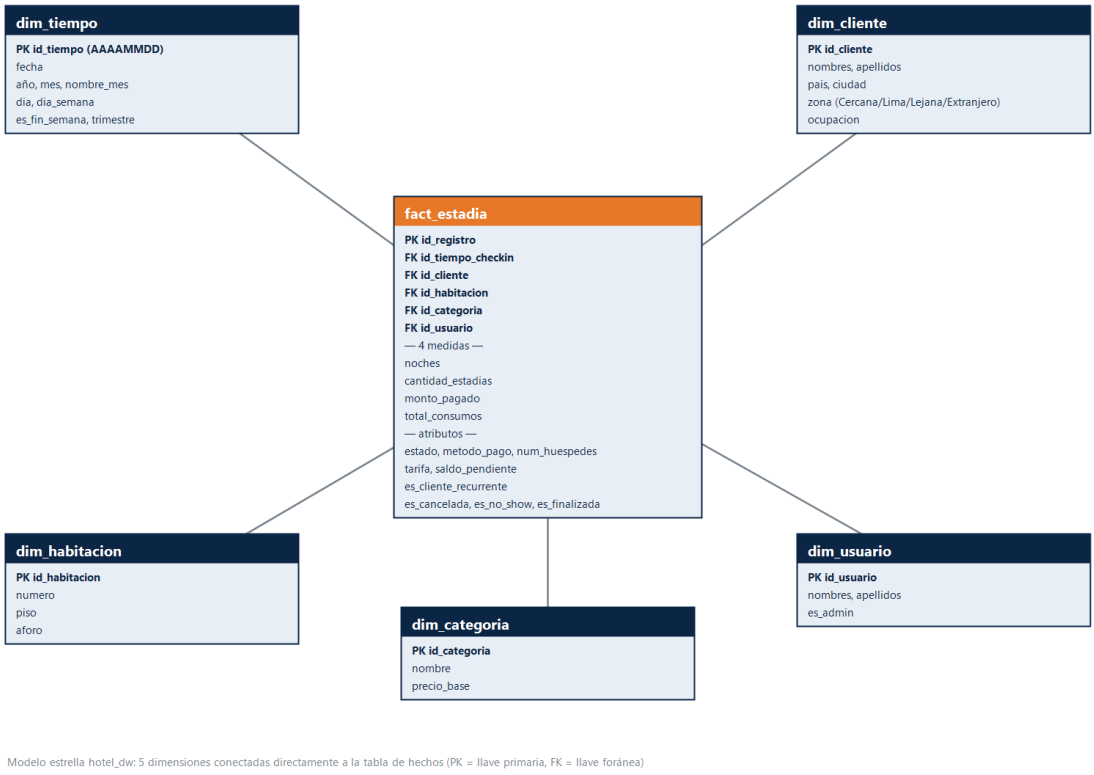


Figura 2. Modelo estrella de hotel_dw: fact_estadia al centro y las cinco dimensiones conectadas directamente. Fuente: elaboración propia a partir de bi/crear_datamart.sql (evidencia E-05).

3.4.3 Procesos ETL/ELT y calidad

El proceso se implementa en dos scripts que se ejecutan cada uno en una sola corrida: bi/crear_datamart.sql crea la base hotel_dw con sus tablas, restricciones, la bitácora etl_log y la tabla etl_calidad; y bi/ETL_CARGA.sql realiza la carga. El ETL es idempotente: su primer paso vacía hechos, dimensiones y staging, por lo que puede repetirse sin duplicar datos. Los ocho pasos son:

PASO	FUENTE	TRANSFORMACIÓN	DESTINO
1. Limpieza	—	delete de hechos y dimensiones; truncate de staging	Todas las tablas (salvo bitácoras)
2. Dimensiones	alquiler (categoria, cliente, usuario)	INSERT … SELECT; zona de origen con CASE según la ciudad y el país	dim_categoria, dim_cliente, dim_usuario
3. Estadías	estadias.txt (separador |)	BULK INSERT dinámico con TRY/CATCH	stg_estadia
4. Consumos	consumos.txt (separador |)	BULK INSERT dinámico con TRY/CATCH	stg_consumo
5. Habitaciones	habitaciones.txt (separador ,)	BULK INSERT y carga de la dimensión	dim_habitacion
6. Calidad de datos	Staging	11 reglas: corrigen o descartan registros y registran el resultado	etl_calidad

PASO	FUENTE	TRANSFORMACIÓN	DESTINO
7. Tiempo	Fechas de check-in	WHILE día por día; DATEPART para año, mes, día, día de la semana y trimestre	dim_tiempo
8. Hechos	Staging + dimensiones	Suma de consumos, saldo, banderas de estado y cliente recurrente (EXISTS)	fact_estadia

Calidad de datos (dónde y cómo). Se aplica en tres niveles. (1) Antes de cargar los hechos, el paso 6 ejecuta once reglas sobre el staging: R01 filas duplicadas (se conserva una), R01B mismo id con datos distintos (se descartan), R02 estadía sin id o sin fecha, R03 estado no válido, R04 noches o huéspedes no positivos, R05 tarifa nula o negativa, R06 monto pagado nulo (se corrige a 0), R07 método de pago vacío (se corrige a NO_REGISTRADO), R08 cliente, habitación o usuario inexistente, R09 consumo sin estadía y R10 consumo con monto no positivo. Cada regla registra en etl_calidad cuántos registros afectó y qué acción tomó. (2) Las claves foráneas del datamart impiden cargar un hecho sin dimensión. (3) Al final se reconcilian estadías y consumos entre origen y destino.

Control de errores. Las cargas de archivos y de la tabla de hechos están dentro de bloques TRY/CATCH; si un paso falla, queda marcado como ERROR en etl_log con el mensaje del motor (ERROR_MESSAGE) y el script continúa con los siguientes pasos. Los archivos se cargan con SQL dinámico (EXEC), lo que permite capturar también un archivo inexistente.

Medición y automatización. Al inicio y al final de cada paso se registra en etl_log la hora (GETDATE y DATEDIFF) y el tiempo de CPU y las lecturas lógicas de la sesión, que SQL Server expone en sys.dm_exec_sessions (Microsoft, 2025b). El archivo bi/ejecutar_etl.bat ejecuta el ETL con sqlcmd y autenticación de Windows y guarda la salida en logs/ultima_ejecucion.log; bi/programar_etl.bat registra la tarea "ETL hotel_dw" en el Programador de tareas para que se ejecute todos los días a las 23:00. Como alternativa, el mismo comando puede programarse como un job de SQL Server Agent. Las funciones usadas son estándar de T-SQL (DATEPART, DATEADD, CAST, MIN, MAX, SUM, COUNT, CASE, EXISTS y BULK INSERT; Microsoft, 2025a); ERROR_MESSAGE, DATEDIFF y sys.dm_exec_sessions se agregan para el control de errores y la medición.

3.4.4 OLAP, reportes y dashboards

El dashboard se construyó en Power BI Desktop como proyecto .pbip (bi/powerbi), conectado a hotel_dw en modo importación. El modelo replica el esquema estrella, marca dim_tiempo como tabla de fechas y define las medidas en DAX: Reservas (SUM de cantidad_estadias), Canceladas, No-show y Finalizadas (CALCULATE con filtro sobre las banderas), % Cancelación, % No-show y % No-llegada (DIVIDE), Ingreso por estadía (ingreso entre estadías finalizadas) y Reservas año anterior y Variación interanual (SAMEPERIODLASTYEAR, mostradas solo cuando se elige un año). Además se crearon dos columnas calculadas para segmentar: tipo de cliente (nuevo o recurrente) y tamaño del grupo. El reporte tiene tres páginas con un filtro de año y filtrado cruzado entre visuales:

- ✓ **Resumen ejecutivo:** tarjetas de los cuatro indicadores y la evolución mensual de reservas y de la tasa de cancelación por año. Decisión: cuándo y cuánto cayó el negocio.
- ✓ **Factores de no-llegada:** tasa de no-llegada por zona de origen, método de pago, categoría, tipo de cliente y tamaño del grupo. Decisión: a qué segmentos dirigir ofertas y en cuáles exigir adelanto.

- ✓ **Comparación interanual:** reservas e ingresos frente al mismo mes del año anterior, con detalle mensual. Decisión: magnitud de la caída de 2026 frente a 2025.

3.5 Diseño de la solución Big Data

3.5.1 Justificación y requisitos Big Data

No aplica: de acuerdo con el alcance definido para esta entrega, el proyecto desarrolla únicamente la solución de Inteligencia de Negocios. El volumen actual (9 036 estadías, alrededor de 2 MB) se procesa en una sola instancia de SQL Server en menos de 4 segundos (capítulo VI), por lo que no se requiere procesamiento distribuido.

3.5.2 Arquitectura y componentes

No aplica: de acuerdo con el alcance definido para esta entrega, el proyecto desarrolla únicamente la solución de Inteligencia de Negocios. El volumen actual (9 036 estadías, alrededor de 2 MB) se procesa en una sola instancia de SQL Server en menos de 4 segundos (capítulo VI), por lo que no se requiere procesamiento distribuido.

3.5.3 Modelo y ciclo de vida de datos

No aplica: de acuerdo con el alcance definido para esta entrega, el proyecto desarrolla únicamente la solución de Inteligencia de Negocios. El volumen actual (9 036 estadías, alrededor de 2 MB) se procesa en una sola instancia de SQL Server en menos de 4 segundos (capítulo VI), por lo que no se requiere procesamiento distribuido.

3.5.4 Escalabilidad, resiliencia y operación

No aplica: de acuerdo con el alcance definido para esta entrega, el proyecto desarrolla únicamente la solución de Inteligencia de Negocios. El volumen actual (9 036 estadías, alrededor de 2 MB) se procesa en una sola instancia de SQL Server en menos de 4 segundos (capítulo VI), por lo que no se requiere procesamiento distribuido.

3.5.5 Resultados

No aplica: de acuerdo con el alcance definido para esta entrega, el proyecto desarrolla únicamente la solución de Inteligencia de Negocios. El volumen actual (9 036 estadías, alrededor de 2 MB) se procesa en una sola instancia de SQL Server en menos de 4 segundos (capítulo VI), por lo que no se requiere procesamiento distribuido.

3.6 Seguridad, privacidad y riesgos

La principal amenaza es la exposición de datos personales de clientes; se mitiga porque los datos de estadías y clientes son simulados, porque el datamart solo guarda los atributos necesarios para el análisis y porque las contraseñas de los usuarios del sistema se almacenan cifradas con BCrypt y no se llevan a hotel_dw. El acceso a la aplicación web está controlado por Spring Security (roles de recepción y administrador, con bloqueo temporal tras intentos fallidos de inicio de sesión). La contraseña de la base de datos no se escribe en el código: la aplicación la recibe por la variable de entorno DB_PASSWORD. SQL Server y Power BI corren en la máquina de desarrollo, sin exposición a internet.

Como respaldo y recuperación, los scripts recrean las bases desde cero: respaldo_bd_actual.sql reconstruye alquiler y crear_datamart.sql junto con ETL_CARGA.sql reconstruyen hotel_dw; además, antes de reemplazar

la base operativa se generó una copia de seguridad (.bak). Como riesgo de interpretación, se declara que los datos son simulados, por lo que sus proporciones no deben leerse como una medición del hotel real (secciones 4.7 y 8.1).

3.7 Plan de despliegue y aceptación

Entorno: desarrollo local en la máquina del equipo; no se definió un entorno de producción en esta entrega. Dependencias: SQL Server 2025 (instancia local, puerto 1433, autenticación mixta), SQL Server Management Studio 22, sqlcmd y Power BI Desktop. El procedimiento detallado se entrega como documento de replicación. Pasos de despliegue:

- ✓ Ejecutar bd/respaldo_bd_actual.sql para crear la base alquiler con sus datos.
- ✓ Copiar los archivos de bi/fuentes/ en C:\txt\tunki\.
- ✓ Ejecutar bi/crear_datamart.sql y luego bi/ETL_CARGA.sql (o bi/ejecutar_etl.bat).
- ✓ Ejecutar una vez bi/programar_etl.bat para dejar el ETL programado todos los días a las 23:00.
- ✓ Abrir bi/powerbi/TunkiLodge_BI.pbip y pulsar Actualizar (credenciales de Windows).

Rollback: los scripts recrean las bases desde cero, por lo que basta con volver a ejecutarlos. Criterios de aceptación: reconciliación del 100 % de estadías y consumos, ETL en menos de 5 segundos con todos los pasos en estado OK, reglas de calidad registradas y dashboard actualizado con los cuatro indicadores. La demostración consiste en ejecutar el ETL, revisar etl_log y etl_calidad y actualizar el dashboard en vivo.

CAPÍTULO IV: DISEÑO DEL EXPERIMENTO

Evidencia principal de la rúbrica 6.1: el capítulo debe permitir que otra persona reproduzca el experimento y comprenda por qué evalúa apropiadamente las soluciones BI y Big Data.

4.1 Pregunta experimental, objetivo e hipótesis

Pregunta experimental: ¿cómo varían el tiempo, el CPU y las lecturas del proceso ETL al aumentar el volumen de estadías; detectan las reglas de calidad los registros defectuosos sin afectar los válidos; y coinciden los indicadores calculados en SQL y en Power BI?

Objetivo: evaluar el costo, la confiabilidad y la exactitud de la solución BI (relación con OE-01, OE-02, OE-03 y OE-04).

- ✓ **H1 (rendimiento).** El costo del ETL crece de forma aproximadamente lineal con el volumen y se mantiene por debajo de 5 segundos hasta 15 000 estadías.
- ✓ **H2 (calidad).** Las reglas de calidad detectan el 100 % de los registros defectuosos inyectados, sin descartar registros válidos, y un archivo faltante queda registrado como error sin detener el proceso.
- ✓ **H3 (exactitud).** Los indicadores calculados con consultas SQL sobre hotel_dw y los mostrados por Power BI coinciden exactamente.

4.2 Escenario y datasets

DATASET	FUENTE Y VERSIÓN	VOLUMEN / FORMATO	CALIDAD Y PRIVACIDAD	USO EN BI / BIG DATA	EVIDENCIA
Original	Base alquiler (SQL Server), script bd/respaldo_bd_actual.sql, datos al 23/10/2026	9 036 estadías, 6 594 clientes, 7 096 consumos; tablas relacionales	Datos simulados, sin personas reales; contraseñas cifradas	Fuente del ETL	E-01
Procesado	hotel_dw, cargado con bi/ETL_CARGA.sql	9 036 hechos, 5 dimensiones, 1 035 días; esquema estrella	Reconciliación 100 % (sección 6.1)	Consultas OLAP y Power BI	E-02
Prueba / sintético	Subconjuntos y copias de estadias.txt; filas defectuosas inyectadas a propósito	Lotes de 500 a 15 000 estadías; 8 estadías y 2 consumos defectuosos	Válido para medir rendimiento y calidad; no representa clientes reales	EXP-01 y EXP-02	E-03

4.3 Variables, métricas y criterios de aceptación

TIPO	VARIABLE / MÉTRICA	DEFINICIÓN Y UNIDAD	MÉTODO DE MEDICIÓN	META / UMBRAL
Independiente	Volumen de estadías (EXP-01); tipo de entrada: limpia, con defectos o con archivo faltante (EXP-02)	Filas; escenario de entrada	Se prepara el archivo antes de cada corrida	500, 1 500, 3 000, 5 000, 8 000, 9 036 y 15 000; 3 escenarios de calidad
Dependiente	Duración, CPU y lecturas del ETL; registros detectados por las reglas; estado de cada paso	ms; páginas de 8 KB; filas/s; registros	Tablas etl_log y etl_calidad	ETL < 5 s; 100 % de defectos detectados
Control	Hardware, edición de SQL Server, scripts, datos base	Valores fijos de la tabla 4.4	Mismo equipo, bases temporales, 3 repeticiones por nivel	Variación entre repeticiones < 30 %
Negocio	Coincidencia de indicadores SQL vs. Power BI; brecha de no-llegada entre segmentos	Valor del indicador; puntos porcentuales	Consultas SQL y tarjetas del dashboard	Diferencia 0; brecha ≥ 10 pp

4.4 Entorno, herramientas y reproducibilidad

Las pruebas se ejecutan en la máquina de desarrollo del equipo, sobre bases temporales (alquiler_prueba y hotel_dw_prueba) que se eliminan al terminar, para no afectar las bases de trabajo. Los datos se generan con semilla fija, por lo que cualquier persona obtiene los mismos registros al ejecutar los scripts del repositorio.

COMPONENTE	VERSIÓN / CONFIGURACIÓN	PROPÓSITO	EVIDENCIA
Hardware	AMD Ryzen 7 7730U (8 núcleos, 16 hilos), 32 GB de RAM	Ejecución de la solución	—
Sistema operativo	Windows 11 Home (compilación 26200)	Plataforma y Programador de tareas	—
Motor de base de datos	SQL Server 2025 Developer (17.0.1000.7), instancia local, puerto 1433	alquiler y hotel_dw	bd/ respaldo_bd_actual.sql, bi/crear_data mart.sql
Cliente SQL	SQL Server Management Studio 22; sqlcmd	Ejecución de scripts y automatización	bi/ ejecutar_etl.bat
Proceso ETL	bi/ETL_CARGA.sql; archivos en C:\txt\tunki\	Carga, calidad y bitácora	bi/ ETL_CARGA.sql , bi/fuentes/

COMPONENTE	VERSIÓN / CONFIGURACIÓN	PROPÓSITO	EVIDENCIA
Visualización	Power BI Desktop 2.158 (septiembre 2026)	Dashboard de indicadores	bi/powerbi/ TunkiLodge_BI. pbip
Aplicación fuente	Spring Boot 3.1.4, Java 17 (Temurin 17.0.20)	Sistema Estadía	Repositorio (src/)

4.5 Matriz de escenarios experimentales

Se definen tres escenarios; las mediciones de rendimiento se repiten tres veces por nivel y se reporta la media y el rango.

ID	SOLUCIÓN	CAMBIO / CONFIGURACIÓN	DATOS	MÉTRICAS	CONTROLES	RESULTADO ESPERADO
EXP-01	BI (ETL)	ETL completo con lotes crecientes de estadías	500, 1 500, 3 000, 5 000, 8 000, 9 036 y 15 000 estadías	Duración, CPU y lecturas (etl_log); filas/s	Mismo equipo y scripts; 3 repeticiones	Crecimiento casi lineal; < 5 s con 15 000
EXP-02	BI (calidad)	ETL con datos limpios, con 10 registros defectuosos y con un archivo faltante	9 036 estadías + defectos inyectados	Registros detectados (etl_calidad); estado por paso (etl_log)	Mismos datos base	100 % de defectos detectados; error registrado sin detener el ETL
EXP-03	BI (exactitud)	Mismo indicador en SQL y en Power BI	hotel_dw completo	Reservas, % cancelación, % no-show, variación interanual	Mismas definiciones de indicador	Diferencia 0

4.6 Procedimiento reproducible

1. Clonar el repositorio en la versión etiquetada y verificar SQL Server 2025, SSMS 22, sqlcmd y Power BI Desktop.
2. Ejecutar bd/respaldo_bd_actual.sql y verificar el conteo de filas que el script muestra al final.
3. Copiar bi/fuentes/ en C:\txt\tunki\, ejecutar bi/crear_datamart.sql y luego bi/ETL_CARGA.sql.
4. EXP-01: preparar cada lote de estadías y ejecutar el ETL tres veces por lote, sin otras cargas en el equipo.
5. EXP-02: ejecutar el ETL con el archivo limpio, con los registros defectuosos agregados y sin consumos.txt.
6. Consultar etl_log y etl_calidad; consolidar media y rango por escenario.
7. EXP-03: comparar los indicadores de las consultas SQL con las tarjetas del dashboard y registrar desviaciones.

4.7 Riesgos, validez y limitaciones del experimento

Validez interna: las mediciones de CPU y lecturas provienen de los contadores de la sesión de SQL Server, con una resolución de algunos milisegundos; en pasos muy rápidos el CPU puede registrarse como 0 ms. Las lecturas lógicas incluyen el trabajo de limpieza de la ejecución anterior, por lo que crecen con las repeticiones. Se realizaron tres repeticiones por nivel y se reporta el rango. Validez externa: los datos son simulados con reglas definidas por el equipo; el experimento demuestra que la solución detecta y mide los patrones, pero no que esas proporciones existan en el hotel real. Para el lote de 15 000 se agregaron copias de estadías con identificador desplazado, válidas para medir rendimiento pero no para analizar el negocio. Restricción de entorno: todo corre en una sola máquina. Limitación: el ETL realiza una carga completa en cada ejecución; la carga incremental queda como recomendación.

CAPÍTULO V: IMPLEMENTACIÓN Y CONTROL DE EVIDENCIAS

5.1 Estructura y versión del repositorio

Repositorio: https://github.com/AlexAmancio/proyecto-bi-bigdata (rama main). Los cambios se integran mediante pull requests revisados; el datamart, el ETL, la automatización y el dashboard corresponden al PR #9 (23/10/2026). Estructura principal:

- ✓ **src/:** aplicación Estadía (Spring Boot 3.1.4, Java 17).
- ✓ **bd/respaldo_bd_actual.sql:** crea la base alquiler con sus 11 tablas y datos, en una sola corrida.
- ✓ **bi/crear_datamart.sql y bi/ETL_CARGA.sql:** modelo estrella, bitácoras y proceso ETL con calidad y control de errores.
- ✓ **bi/ejecutar_etl.bat y bi/programar_etl.bat:** automatización del ETL.
- ✓ **bi/fuentes/:** los tres archivos planos del ETL.
- ✓ **bi/powerbi/:** dashboard de Power BI (proyecto .pbip).
- ✓ **README.md:** instrucciones para levantar la aplicación y reproducir las bases.

5.2 Implementación de la solución BI

La solución se implementó en cuatro componentes. Primero, la base operativa alquiler se migró de MySQL a SQL Server: se cambió el controlador de la aplicación (mssql-jdbc), la conexión y el tipo de las columnas de texto largo, y se convirtió el script de la base a T-SQL con creación en una sola corrida; se eliminaron dos tablas sin uso (rol y usuarios_roles), porque los roles se manejan con el campo es_admin.

Segundo, el datamart hotel_dw (bi/crear_datamart.sql) y el ETL de ocho pasos (bi/ETL_CARGA.sql) descritos en 3.4.2 y 3.4.3. Durante la implementación se decidió conectar la categoría directamente a los hechos para conservar un esquema estrella; calcular la zona de origen en el ETL; usar un conjunto reducido de funciones estándar (CASE, DATEPART y EXISTS en lugar de ISNULL, CONVERT o ROW_NUMBER); quitar la clave primaria del staging para que los duplicados se traten como regla de calidad y no como un error de carga; y reemplazar NOT IN por NOT EXISTS en las reglas, lo que redujo el paso de calidad de 21.7 s a 1.2 s.

Tercero, la automatización: ejecutar_etl.bat ejecuta el ETL con sqlcmd y programar_etl.bat registra la tarea diaria. Cuarto, el dashboard de Power BI (bi/powerbi), con el modelo, las medidas DAX y las tres páginas descritas en 3.4.4.

5.3 Implementación de la solución Big Data

No aplica: de acuerdo con el alcance definido para esta entrega, el proyecto desarrolla únicamente la solución de Inteligencia de Negocios. El volumen actual (9 036 estadías, alrededor de 2 MB) se procesa en una sola instancia de SQL Server en menos de 4 segundos (capítulo VI), por lo que no se requiere procesamiento distribuido.

5.4 Calidad, seguridad y pruebas

ID PRUEBA	REQUISITO	ENTRADA / CONDICIÓN	RESULTADO ESPERADO	RESULTADO	EVIDENCIA
T-01	RF-01	ETL completo sobre 9 036 estadías	Estadías y consumos de origen = destino	9 036 = 9 036; S/ 200 014 = S/ 200 014. Cumple	E-06, E-07

ID PRUEBA	REQUISITO	ENTRADA / CONDICIÓN	RESULTADO ESPERADO	RESULTADO	EVIDENCIA
T-02	RF-01	Comparación de cada hecho con su registro original	0 diferencias	0 diferencias; 0 claves nulas. Cumple	E-06
T-03	RF-03	ETL con 8 estadías y 2 consumos defectuosos inyectados	Defectos detectados y registrados	14 registros detectados por 9 reglas; 9 036 hechos válidos. Cumple	E-10
T-04	RF-04	ETL sin el archivo consumos.txt	Paso en ERROR con mensaje; el resto continúa	Paso 4 en ERROR con el mensaje del motor; pasos 5 a 8 en OK. Cumple	E-10
T-05	RNF-01	Ejecutar ETL_CARGA.sql dos veces seguidas	Mismo resultado, sin duplicados	9 036 hechos en ambas ejecuciones. Cumple	E-10
T-06	RNF-01	Duración del ETL con 9 036 estadías	< 5 s	2.5 s de media (3 repeticiones). Cumple	E-10
T-07	RNF-02	Ejecutar bi/ejecutar_etl.bat sin abrir SSMS	ETL completo con autenticación de Windows	8 pasos en OK; log en logs/ultima_ejecucion .log. Cumple	E-06
T-08	RF-05	Actualizar el dashboard después del ETL	Indicadores iguales a SQL	Reservas 9 036; % cancelación 6.2 %; variación 2026 −25.1 %. Cumple	E-07
T-09	RNF-04	Buscar credenciales en el repositorio	Ninguna contraseña en texto plano	Contraseña por DB_PASSWORD; ETL y Power BI con autenticación de Windows. Cumple	E-06

5.5 Registro de retroalimentación y mejoras

FECHA	RETROALIMENTACIÓN	ACCIÓN / DECISIÓN	EVIDENCIA ANTES-DESPUÉS	RESP.
07/10/2026	Revisión de avance: el ETL debe integrar al menos tres fuentes en archivos planos	Se agregaron estadias.txt, consumos.txt y habitaciones.txt, cargados con BULK INSERT	E-12 / PR #9	<<Integrante >>
20/10/2026	Revisión de avance: ¿qué ocurre si llegan lotes de 500, 1 500, 3 000, 5 000, 8 000 y 15 000 registros?	Se ejecutó EXP-01 con esos lotes y se agregó la bitácora etl_log	E-12 / PR #9	<<Integrante >>
20/10/2026	Revisión de avance: cada script debe crear y cargar todo en una sola ejecución	Scripts de base, datamart y ETL ejecutables en una sola corrida	E-12 / PR #6, PR #9	<<Integrante >>
23/10/2026	Revisión de avance: medir cuánto CPU consume el proceso ETL	Registro de duración, CPU y lecturas por paso en etl_log	E-12 / PR #9	<<Integrante >>

FECHA	RETROALIMENTACIÓN	ACCIÓN / DECISIÓN	EVIDENCIA ANTES-DESPUÉS	RESP.
23/10/2026	Revisión de avance: usar funciones estándar y justificar las adicionales	Se reemplazaron ISNULL, CONVERT y ROW_NUMBER; se justifican ERROR_MESSAGE, DATEDIFF y sys.dm_exec_sessions	E-12 / PR #9	<<Integrante >>
23/10/2026	Pautas de entrega: ETL automatizado con calidad de datos y dashboard en Power BI	Paso de calidad con 11 reglas, TRY/CATCH, tarea programada y dashboard .pbip	E-12 / PR #9	<<Integrante >>

5.6 Contribuciones individuales

INTEGRANTE	RESPONSABILIDADES	COMMITS / ARTEFACTOS	VALIDACIÓN DEL EQUIPO	%
Ayala Hernandez, Gerardo	<<Aportes verificables>>	<<Enlaces/commits>>	<<Conformidad>>	100 %
Bringas Veramendi, Julio Cesar Ricardo	<<Aportes verificables>>	<<Enlaces/commits>>	<<Conformidad>>	100 %
Osorio Carbajal, Mijai	<<Aportes verificables>>	<<Enlaces/commits>>	<<Conformidad>>	100 %
Racchumi Julon, Yeremi Adrian	<<Aportes verificables>>	<<Enlaces/commits>>	<<Conformidad>>	100 %
Valencia Amancio, Alex	<<Aportes verificables>>	PR #4 a #9 del repositorio	<<Conformidad>>	100 %

5.7 Declaración de uso responsable de inteligencia artificial

HERRAMIENTA	FINALIDAD	CONTENIDO UTILIZADO	VERIFICACIÓN HUMANA	RIESGOS / PRIVACIDAD
Claude (Anthropic), mediante Claude Code	Apoyo en la generación y depuración de scripts T-SQL, del generador de datos simulados y de la migración a SQL Server; revisión de redacción	Código (scripts SQL y generador), estructura de tablas y borradores de texto	Ejecución de los scripts en SQL Server, reconciliación origen–destino, revisión de cada cambio en pull requests y revisión del texto por el equipo	No se ingresaron datos personales reales; los datos son simulados. Las decisiones de diseño y la interpretación de resultados son del equipo

CAPÍTULO VI: EJECUCIÓN, RESULTADOS Y ANÁLISIS DE DATOS

Evidencia principal de la rúbrica 6.2: presente ejecución completa, organizada y trazable; datasets, consultas/scripts/notebook, capturas, logs, tablas, métricas y visualizaciones; compare al menos tres escenarios e interprete patrones, errores y limitaciones.

6.1 Validación del dataset original y procesado

CONTROL	ORIGINAL	PROCESADO	REGLA / UMBRAL	RESULTADO Y EVIDENCIA
Registros / tamaño	9 036 estadías; 7 096 consumos (S/ 200 014)	9 036 hechos; S/ 200 014 en total_consumos	Origen = destino	Cumple: 100 % reconciliado (E-06)
Completitud	100 % de estadías con cliente, habitación, usuario y fecha	0 claves nulas en fact_estadia	100 %	Cumple
Duplicados	0 (id_registro único)	0 (clave primaria id_registro)	0	Cumple
Consistencia / validez	Estado, noches, cliente, categoría, método y monto pagado	0 diferencias registro por registro; monto pagado S/ 5 783 274 = S/ 5 783 274	0 diferencias	Cumple

6.2 Registro de ejecuciones

EJECUCIÓN	VERSIÓN / FECHA	ESCENARIO	CONFIGURACIÓN	ESTADO / LOG
RUN-01	PR #9, 23/10/2026 20:22	Carga de trabajo	hotel_dw, 9 036 estadías; ejecutado con ejecutar_etl.bat	Exitoso; 8 pasos en OK (etl_log, ejecución 1)
RUN-02 a RUN-22	PR #9, 23/10/2026	EXP-01	7 lotes × 3 repeticiones, en base temporal	Exitosos; 0 pasos en ERROR
RUN-23	PR #9, 23/10/2026	EXP-02 (limpio)	9 036 estadías sin defectos	Exitoso; 0 registros afectados
RUN-24	PR #9, 23/10/2026	EXP-02 (defectos)	9 036 + 8 estadías y 2 consumos defectuosos	Exitoso; 14 registros detectados
RUN-25	PR #9, 23/10/2026	EXP-02 (archivo faltante)	Sin consumos.txt	Paso 4 en ERROR registrado; resto OK

Consumo registrado en etl_log para RUN-01:

PASO DEL ETL	DURACIÓN (ms)	CPU (ms)	ESTADO	FILAS
1. Limpieza de tablas	40	15	OK	0
2. Dimensiones desde alquiler	90	63	OK	6 609
3. Staging estadias.txt	117	109	OK	9 036
4. Staging consumos.txt	97	79	OK	7 096
5. dim_habitacion	37	0	OK	45
6. Calidad de datos	1 377	1 203	OK	0 afectados
7. dim_tiempo	290	125	OK	1 035
8. fact_estadia	463	406	OK	9 036
Total	2 511	2 000	8 OK	—

6.3 Tabla consolidada de resultados

EXP-01: media de tres repeticiones por lote (rango entre paréntesis).

LOTE	DURACIÓN TOTAL	CPU TOTAL	PASO 6 (CALIDAD)	PASO 8 (HECHOS)	THROUGHPUT	ERRORES
500	0.67 s (0.62–0.70)	0.53 s	0.25 s	0.14 s	≈ 745 filas/s	0
1 500	0.93 s (0.92–0.96)	0.75 s	0.37 s	0.17 s	≈ 1 610 filas/s	0
3 000	1.43 s (1.32–1.60)	1.18 s	0.51 s	0.23 s	≈ 2 100 filas/s	0
5 000	2.52 s (2.04–2.84)	2.30 s	0.73 s	0.32 s	≈ 1 980 filas/s	0
8 000	2.69 s (2.11–3.67)	2.35 s	1.15 s	0.42 s	≈ 2 980 filas/s	0
9 036	2.44 s (2.41–2.50)	2.08 s	1.16 s	0.48 s	≈ 3 700 filas/s	0
15 000	3.46 s (3.41–3.49)	3.16 s	1.80 s	0.79 s	≈ 4 340 filas/s	0

EXP-02: resultado de las reglas de calidad.

ESCENARIO	REGLAS QUE ACTUARON	REGISTROS AFECTADOS	RESULTADO
Datos limpios	Ninguna	0	9 036 hechos; todos los pasos OK
Con defectos inyectados	R01, R01B, R03, R04, R05, R06, R07, R08, R09, R10	14 (1 duplicado, 2 ids en conflicto, 4 inválidos, 2 corregidos, 5 consumos)	100 % detectado; solo llegan registros válidos
Sin consumos.txt	Control de errores (TRY/CATCH)	—	Paso 4 en ERROR con el mensaje del motor; pasos 5 a 8 en OK

EXP-03: indicadores calculados en SQL y en Power BI.

INDICADOR	SQL (hotel_dw)	POWER BI	DIFERENCIA
Reservas 2024–2026	9 036	9 036	0
% cancelación (todo el periodo)	6.2 %	6.2 %	0
% no-show (todo el periodo)	3.4 %	3.4 %	0
Reservas ene–oct 2026 vs. 2025	2 179 vs. 2 909 (−25.1 %)	2 179 vs. 2 909 (−25.1 %)	0

Resultados de negocio (estadías con llegada hasta el 23/10/2026):

FACTOR	MAYOR NO-LLEGADA	MENOR NO-LLEGADA	BRECHA
Zona de origen	Lejana: 15.2 % (Extranjero 14.6 %)	Cercana a Oxapampa: 4.5 % (Lima 8.6 %)	10.7 pp
Método de pago	Efectivo: 13.5 %	Transferencia: 6.8 % (Tarjeta 8.3 %)	6.7 pp
Categoría	Cabaña Bungalow: 15.9 % (Domo Colibrí 14.3 %)	Habitación Matrimonial: 7.0 %	8.9 pp
Tamaño del grupo	5 o más huéspedes: 13.5 %	1 a 4 huéspedes: 8.8 %	4.7 pp
Tipo de cliente	Nuevo: 10.7 %	Recurrente: 6.6 %	4.1 pp
Solo 2026: zona y pago	Lejana 21.5 %; Efectivo 19.8 %	Cercana 6.9 %; Transferencia 7.7 %	14.6 pp; 12.1 pp

Además, la participación de los segmentos de mayor riesgo creció en 2026: las reservas pagadas en efectivo pasaron de 29.4 % en 2025 a 43.5 % en 2026, y las de clientes de zonas lejanas de 25.9 % a 34.2 %.

6.4 Visualizaciones y dashboards

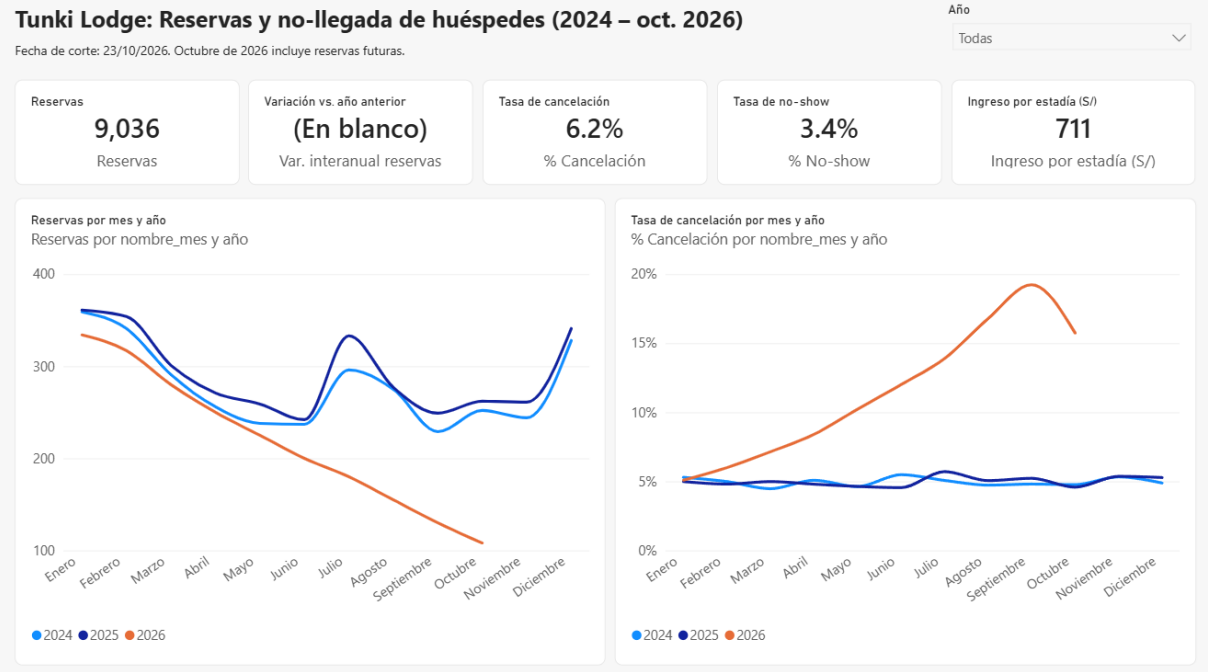


Figura 3. Resumen ejecutivo: reservas y tasa de cancelación por mes y año. Fuente: elaboración propia a partir de hotel_dw (evidencia E-07).

La curva de 2026 cae de forma sostenida desde enero, mientras 2024 y 2025 siguen la estacionalidad habitual (picos en enero, julio y diciembre); la tasa de cancelación de 2026 se separa de la línea estable de 5 % desde febrero y llega a 19.2 % en septiembre. Decisión: el problema no es estacional, sino una tendencia que exige acción comercial.

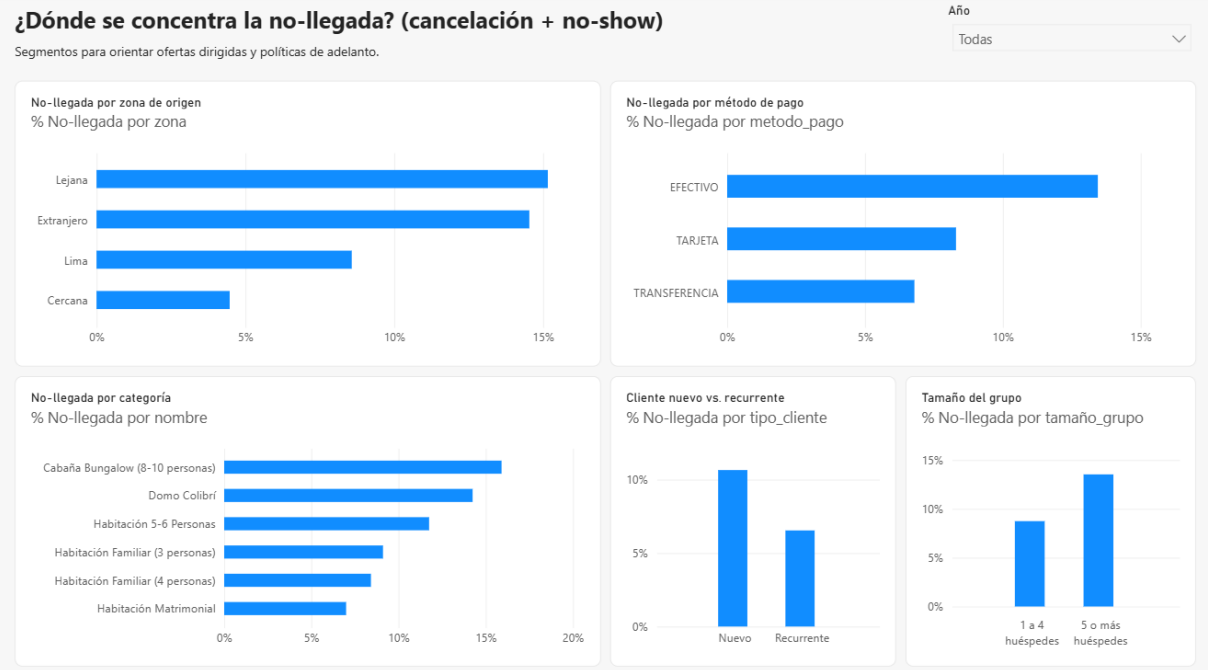


Figura 4. Factores de no-llegada por zona de origen, método de pago, categoría, tipo de cliente y tamaño del grupo. Fuente: elaboración propia a partir de hotel_dw (evidencia E-07).

Los segmentos con mayor no-llegada son los clientes de ciudades lejanas y extranjeros, el pago en efectivo, las categorías grandes (Cabaña y Domo), los clientes nuevos y los grupos de cinco o más. Decisión: dirigir ofertas y políticas de adelanto a esos segmentos.



nombre_mes	Reservas	Reservas año anterior	Var. interanual reservas	% Cancelación
Enero	334	361	-7.5%	5.1%
Febrero	317	354	-10.5%	6.0%
Marzo	280	301	-7.0%	7.1%
Abril	250	271	-7.7%	8.4%
Mayo	225	259	-13.1%	10.2%
Junio	200	242	-17.4%	12.0%
Julio	180	333	-45.9%	13.9%
Agosto	155	277	-44.0%	16.8%
Septiembre	130	249	-47.8%	19.2%
Octubre	108	262	-58.8%	15.7%
Total	**2,179**	**2,909**	**-25.1%**	**10.0%**

Figura 5. Comparación interanual 2026 frente a 2025. Fuente: elaboración propia a partir de hotel_dw (evidencia E-07).

Cada mes de 2026 queda por debajo del mismo mes de 2025; la caída pasa de −7.5 % en enero a −58.8 % en octubre, y el ingreso cobrado cae 30.2 %. Decisión: priorizar la recuperación de julio a octubre, donde la brecha es mayor.

6.5 Análisis e interpretación técnica

Rendimiento (H1). El costo del ETL crece de forma casi lineal: al pasar de 500 a 15 000 estadías (30 veces más datos) la duración pasa de 0.67 s a 3.46 s (5 veces más), porque existe un costo fijo de alrededor de medio segundo (limpieza, dimensiones y calendario) que no depende del volumen. Con 15 000 estadías el ETL sigue por debajo de 5 s, por lo que H1 se cumple. El paso más costoso no es la tabla de hechos sino la calidad de datos (52 % del tiempo con 15 000 filas), porque sus reglas recorren el staging varias veces; es el principal punto de mejora. La variación entre repeticiones fue mayor en 5 000 y 8 000 filas (hasta 1.5 s), atribuible a otras tareas del sistema operativo durante la medición.

Calidad (H2). Las reglas detectaron los 14 registros defectuosos inyectados (100 %) y los 9 036 válidos llegaron al datamart; un archivo faltante quedó registrado como ERROR sin detener los pasos siguientes. H2 se cumple. Un hallazgo de la implementación fue que la condición NOT IN sobre 9 000 filas hacía que el paso tardara 21.7 s; con NOT EXISTS bajó a 1.2 s (−94 %).

Exactitud (H3). Los indicadores coinciden exactamente entre SQL y Power BI (diferencia 0), lo que valida las medidas DAX y la relación con dim_tiempo. H3 se cumple.

Negocio. La brecha de no-llegada entre zona lejana (15.2 %) y cercana (4.5 %) es de 10.7 puntos porcentuales y en 2026 llega a 14.6 pp; con el método de pago llega a 12.1 pp en 2026. Además, la participación de los segmentos de mayor riesgo creció: el pago en efectivo pasó de 29.4 % a 43.5 % de las reservas y la zona lejana

de 25.9 % a 34.2 %. Esto es una asociación observada en los datos, no una relación causal demostrada: el experimento no permite afirmar que el pago en efectivo cause la cancelación.

6.6 Verificación de funcionalidad y completitud

PRODUCTO	CRITERIOS DE ACEPTACIÓN	RESULTADO	ESTADO	EVIDENCIA
Solución BI	RF-01 a RF-05; RNF-01 a RNF-04	Datamart, ETL con calidad y control de errores, automatización y dashboard validados (T-01 a T-09)	Cumple	E-13
Solución Big Data	No aplica en el alcance de esta entrega	—	No aplica	—
Integración / despliegue	Scripts reproducibles en una sola corrida; ETL programado; dashboard conectado	Bases recreadas desde cero; tarea diaria; Power BI actualizado con los mismos valores que SQL	Cumple	E-06, E-07

CAPÍTULO VII: CONCLUSIONES TÉCNICAS Y RECOMENDACIONES

Evidencia principal de la rúbrica 6.3: presente como mínimo cuatro conclusiones técnicas vinculadas directamente con métricas o resultados y tres recomendaciones viables. Justifique decisiones con evidencia y juicio de ingeniería.

7.1 Matriz objetivo-resultado-conclusión-recomendación

OBJETIVO	RESULTADO / MÉTRICA	CONCLUSIÓN TÉCNICA	RECOMENDACIÓN / DECISIÓN	EVIDENCIA
OE-01	Estrella de 5 dimensiones y 4 medidas; 9 036 = 9 036; 0 diferencias	El datamart integra las fuentes sin pérdida y con integridad referencial	Mantener la reconciliación como control de cada carga	E-06, E-07
OE-02	11 reglas; 100 % de defectos detectados; errores registrados; tarea diaria	El ETL es confiable y operable sin intervención manual	Agregar alertas por correo ante un paso en ERROR	E-10
OE-03	Dashboard de 3 páginas; variación 2026 −25.1 %; brecha 10.7 pp por zona	Los indicadores explican la caída y señalan los segmentos de riesgo	Ofertas dirigidas: prepago, zonas cercanas, clientes recurrentes	E-07
OE-04	15 000 estadías en 3.46 s; SQL = Power BI	La solución escala de forma casi lineal y sus indicadores son exactos	Carga incremental e índices en el staging	E-09

7.2 Conclusiones técnicas

C1. La caída de reservas de Tunki Lodge es una tendencia y no un efecto estacional: entre enero y octubre de 2026 las reservas bajaron 25.1 % y el ingreso 30.2 % frente a 2025, con meses de hasta −58.8 %, mientras la tasa de cancelación pasó de 5.1 % a 19.2 % (Figuras 3 y 5).

C2. La no-llegada se concentra en segmentos identificables: zona lejana frente a cercana (15.2 % frente a 4.5 %, brecha de 10.7 pp que cumple el objetivo de 10 pp) y pago en efectivo frente a transferencia (13.5 % frente a 6.8 %); además, estos segmentos ganaron participación en 2026, lo que explica parte de la caída (Figura 4).

C3. El ETL de ocho pasos es confiable: reconcilia el 100 % de las filas, detectó el 100 % de los registros defectuosos inyectados mediante 11 reglas y registra los errores sin detener el proceso, con una ejecución automática diaria (EXP-02, T-03, T-04, T-07).

C4. El costo del ETL crece de forma casi lineal (de 0.67 s con 500 estadías a 3.46 s con 15 000) y el paso más costoso es la calidad de datos; reemplazar NOT IN por NOT EXISTS redujo ese paso en 94 %, lo que muestra que el diseño de las consultas pesa más que el volumen actual (EXP-01).

C5. Los indicadores del dashboard coinciden exactamente con las consultas SQL sobre el datamart, por lo que las medidas DAX y el modelo estrella son una base confiable para la toma de decisiones (EXP-03).

7.3 Recomendaciones

R1 (prioridad alta, negocio). Implementar ofertas dirigidas en lugar de descuentos generales: descuento por prepago con tarjeta o transferencia, campañas en ciudades cercanas a Oxapampa (Huancayo, La Merced, Huánuco) y beneficios para clientes recurrentes; exigir adelanto en Cabaña y Domo y en grupos de cinco o más. Impacto esperado: reducir la no-llegada en los segmentos de mayor riesgo y medir el efecto en el mismo dashboard.

R2 (prioridad alta, sistema). Registrar en el sistema Estadía la fecha en que se hace la reserva y el canal, para incorporar la anticipación y el canal como dimensiones. Impacto: completar el análisis de factores de no-llegada.

R3 (prioridad media, ETL). Pasar a una carga incremental (solo registros nuevos o modificados, con MERGE y una marca de la última carga) y agregar índices en las columnas de staging usadas por las reglas de calidad. Impacto: reducir el tiempo del paso más costoso a medida que crezca el volumen.

R4 (prioridad media, operación). Agregar alertas por correo cuando un paso termine en ERROR o una regla de calidad supere un umbral, y programar la actualización del dashboard después del ETL. Impacto: detectar problemas sin revisar manualmente las bitácoras.

CAPÍTULO VIII: RESPONSABILIDAD ÉTICA Y PROFESIONAL

8.1 Tratamiento ético, legal y seguro de los datos

Los datos de estadías, clientes y consumos usados en el análisis son simulados y no corresponden a personas reales, lo que evita tratar datos personales sin consentimiento; aun así, el diseño aplica los principios de la Ley N.° 29733, Ley de Protección de Datos Personales del Perú, como si se tratara de datos reales. Se aplica minimización: el datamart no guarda documento de identidad, teléfono, correo ni contraseñas, solo los atributos necesarios para el análisis. Las contraseñas de los usuarios del sistema se almacenan cifradas con BCrypt y la contraseña de la base se pasa por variable de entorno. En sesgo y explicabilidad, los patrones del dataset provienen de reglas definidas por el equipo, que se documentan en el informe; por eso los resultados se presentan como capacidad de detección de la solución y no como una afirmación sobre el comportamiento real de los huéspedes. Una consecuencia a evitar es usar la segmentación para discriminar clientes: la zona de origen o el método de pago deben servir para diseñar ofertas y políticas de confirmación, no para negar reservas.

8.2 Impactos de las soluciones

En lo organizacional, la solución BI da a la gerencia y al área comercial una vista consolidada de las reservas que hoy no existe, y permite pasar de descuentos generales a ofertas dirigidas a los segmentos con mayor no-llegada. En lo económico, reducir la no-llegada libera habitaciones que hoy quedan bloqueadas sin ingreso; en 2026 se perdieron 310 estadías por cancelación o no-show entre enero y la fecha de corte. En lo social, se debe cuidar que las políticas derivadas (como exigir adelanto) no excluyan a clientes que solo pueden pagar en efectivo. En lo ambiental, el procesamiento se ejecuta en una sola máquina, sin infraestructura adicional. El principal riesgo de interpretación es confundir correlación con causalidad: que un segmento cancele más no prueba que su característica cause la cancelación.

8.3 Compromiso profesional

El equipo asume la responsabilidad de que los resultados sean reproducibles: los scripts, los archivos planos y las reglas de generación de datos están versionados, y cualquier persona puede recrear las bases y obtener las mismas cifras. Se declara de forma transparente que los datos son simulados, que la anticipación de la reserva no pudo medirse y que la escalabilidad se probó en una sola máquina. Los cambios al código se integran mediante pull requests revisados, y el uso de herramientas de inteligencia artificial se declara en la sección 5.7. El equipo se compromete a no presentar los resultados como mediciones del hotel real y a no usar la segmentación de clientes con fines discriminatorios.

REFERENCIAS BIBLIOGRÁFICAS

ABET. (2026). Criteria for Accrediting Engineering Programs, 2026-2027. https://www.abet.org/accreditation/accreditation-criteria/criteria-for-accrediting-engineering-programs-2026-2027/

ABET. (s. f.). Assessment Planning. https://www.abet.org/accreditation/get-accredited/assessment-planning/

Antonio, N., de Almeida, A., y Nunes, L. (2017). Predicting hotel bookings cancellation with a machine learning classification model. En 2017 16th IEEE International Conference on Machine Learning and Applications (ICMLA) (pp. 1049-1054). IEEE.

Antonio, N., de Almeida, A., y Nunes, L. (2019). Big data in hotel revenue management: Exploring cancellation drivers to gain insights into booking cancellation behavior. Cornell Hospitality Quarterly, 60(4), 298-319. https://doi.org/10.1177/1938965519851466

Chen, S., Ngai, E. W. T., Ku, Y., Xu, Z., Gou, X., y Zhang, C. (2023). Prediction of hotel booking cancellations: Integration of machine learning and probability model based on interpretable feature interaction. Decision Support Systems, 170, 113959. https://doi.org/10.1016/j.dss.2023.113959

Golfarelli, M., y Rizzi, S. (2018). From star schemas to big data: 20+ years of data warehouse research. En S. Flesca, S. Greco, E. Masciari, y D. Saccà (Eds.), A comprehensive guide through the Italian database research over the last 25 years (pp. 93-107). Springer. https://doi.org/10.1007/978-3-319-61893-7_6

Kimball, R., y Ross, M. (2013). The data warehouse toolkit: The definitive guide to dimensional modeling (3.ª ed.). Wiley.

Kirmani, M. M. (2017). Dimensional modeling using star schema for data warehouse creation. Oriental Journal of Computer Science and Technology, 10(3), 745-754.

Ley N.° 29733, Ley de Protección de Datos Personales. (2011). Diario Oficial El Peruano.

Microsoft. (2025a). BULK INSERT (Transact-SQL). Microsoft Learn. https://learn.microsoft.com/es-es/sql/t-sql/statements/bulk-insert-transact-sql

Microsoft. (2025b). sys.dm_exec_sessions (Transact-SQL). Microsoft Learn. https://learn.microsoft.com/es-es/sql/relational-databases/system-dynamic-management-views/sys-dm-exec-sessions-transact-sql

ANEXOS Y MANIFIESTO DE EVIDENCIAS

CÓDIGO	EVIDENCIA	UBICACIÓN / ENLACE	VERSIÓN / FECHA	RESPONSABLE
E-01	Dataset original y ficha de procedencia	bd/ respaldo_bd_actual.sql (base alquiler)	PR #9 / 23/10/2026	<<Nombre>>
E-02	Dataset procesado y perfil de calidad	hotel_dw; sección 6.1; tabla etl_calidad	PR #9 / 23/10/2026	<<Nombre>>
E-03	Datos de prueba/sintéticos y método	Reglas de simulación (sección 1.4); lotes y defectos de EXP-01 y EXP-02	PR #8, PR #9	<<Nombre>>
E-04	Diseño experimental y configuraciones	Capítulo IV	23/10/2026	<<Nombre>>
E-05	Diagrama de arquitectura y esquema de datos	Figuras 1 y 2	23/10/2026	<<Nombre>>
E-06	SQL/NoSQL/Spark, scripts y notebook	bd/, bi/crear_datamart.sql, bi/ETL_CARGA.sql, bi/*.bat, bi/fuentes/	PR #9	<<Nombre>>
E-07	Resultados de la solución BI	bi/powerbi/ TunkiLodge_BI.pbip; Figuras 3 a 5	PR #9	<<Nombre>>
E-08	Resultados de la solución Big Data	No aplica	—	—
E-09	Comparación de escenarios y métricas	Secciones 6.3 y 6.5	23/10/2026	<<Nombre>>
E-10	Logs, capturas y visualizaciones	Tablas etl_log y etl_calidad; bi/logs/ultima_ejecucion. log	23/10/2026	<<Nombre>>
E-11	Conclusiones, recomendaciones y decisiones	Capítulo VII	23/10/2026	<<Nombre>>
E-12	Retroalimentación y mejoras implementadas	Sección 5.5; pull requests #4 a #9	23/10/2026	<<Nombre>>
E-13	Solución BI funcional / demostración	Repositorio + dashboard Power BI + procedimiento de replicación	PR #9	<<Nombre>>
E-14	Solución Big Data funcional / demostración	No aplica	—	—
E-15	Aportes individuales y defensa	Sección 5.6; historial del repositorio	<<Versión>>	<<Nombre>>
E-16	Declaración de uso responsable de IA	Sección 5.7 y declaración final	23/10/2026	<<Nombre>>

Lista de anexos sugeridos

1. Anexo A. Requisitos, historias de usuario y criterios de aceptación.

2. Anexo B. Diccionario de datos, modelos y diagramas de arquitectura.
3. Anexo C. Fichas de datasets original, procesado y de prueba.
4. Anexo D. Scripts SQL/NoSQL/Spark, notebooks y archivos de configuración.
5. Anexo E. Logs, tablas completas, visualizaciones y capturas de ejecución.
6. Anexo F. Manual de instalación, despliegue, operación y demostración.
7. Anexo G. Evidencia de retroalimentación, mejoras y aceptación.
8. Anexo H. Historial de repositorio y aportes individuales.
9. Anexo I. Declaración de uso responsable de IA.

DECLARACIÓN DE USO RESPONSABLE DE INTELIGENCIA ARTIFICIAL

La IA puede utilizarse como apoyo, pero no reemplaza el análisis, la simulación, la interpretación de resultados ni la responsabilidad académica del estudiante/equipo.

Responda de manera honesta:

Aspecto	Respuesta
1. ¿Utilicé IA?	☐ No ☐ Sí
2. Herramienta	☐ ChatGPT ☐ Gemini ☐ Copilot ☐ Claude ☐ Otra:_____
3. ¿Para qué la utilicé?	☐ Ideas ☐ Redacción ☐ Código ☐ Errores ☐ Gráficos ☐ Análisis ☐ Otra: _____
4. ¿En qué parte?	☐ Diagrama ☐ Código ☐ Resultados ☐ Análisis ☐ Conclusiones ☐ Reporte ☐ Otra: _____
5. ¿Cómo validé lo que la IA me proporcionó?	☐ Ejecuté el código ☐ Comparé resultados ☐ Revisé fórmulas/unidades ☐ Validé con simulador ☐ Corregí errores

Declaración ética

Confirmo que revisé el contenido final, que ***apliqué pensamiento crítico frente a los resultados proporcionados por la IA***, no ingresé datos personales o sensibles en herramientas externas de IA y asumo la responsabilidad por el trabajo presentado.

Nombre(s)	Firmas

Fecha (dd/mm/yyyy)	

Revisión rápida del docente:

☐ Declara uso de IA.

☐ Evidencia validación manual.

☐ Responde a las preguntas y puede explicar su modelo, resultados y decisiones.

Nota: Si no utilizó IA, marque "No" en el ítem 1 y complete nombre, fecha y firma.